

ANÁLISIS EXPLORATORIO DE USUARIOS DE UNA PLATAFORMA DE STREAMING

Informe final - Proyecto Integrador de Minería de Datos I

Integrantes: Thir Ferreyra Nadia Lorena y Constantinidi Leandro Exequiel

Comisión: Turno Tarde

Fecha: 27 de junio de 2026

Carrera: Tecnicatura Superior en Ciencia de Datos e Inteligencia Artificial

Profesor: Fernando Elías Mubarqui

Fuente: Dataset provisto por la cátedra

1. Objetivo y alcance

El proyecto tuvo como objetivo inspeccionar, preparar y analizar un dataset de usuarios de una plataforma de streaming, relacionando el plan de suscripción, la edad y el país con el tiempo mensual de visualización. El alcance fue descriptivo y exploratorio: no se desarrollaron modelos predictivos ni se realizaron afirmaciones causales.

2. Metodología y calidad de datos

El trabajo siguió una secuencia reproducible: inspección inicial, limpieza y validación, análisis univariado, bivariado y multivariado, escalamiento y PCA. Cada transformación se registró en un log ETL y se mantuvo el archivo original sin modificaciones.

Evidencia inicial	Decisión principal	Resultado final
8.160 filas y 160 IDs repetidos	Conservar la primera aparición de cada usuario	8.000 usuarios únicos; retención 98,04 %
Categorías equivalentes escritas de distintas formas	Estandarizar mediante diccionarios explícitos	3 planes, 7 países y categorías de género consistentes
Edades, minutos y tickets imposibles	Marcar como faltantes e imputar con medianas justificadas	Rangos coherentes sin eliminar usuarios
Fechas ambiguas, imposibles o futuras	No inventar fechas	501 fechas permanecen desconocidas

3. Principales resultados exploratorios

Indicador	Resultado	Interpretación
Distribución por plan	Básico 45,0 %; Estándar 35,2 %; Premium 19,8 %	La base se concentra en Básico y Estándar.
Consumo mensual	Media 800,9; mediana 770,8 minutos	La cola de usuarios intensivos eleva el promedio.
Medianas por plan	552,7; 840,0; 1127,0 minutos	El consumo aumenta de Básico a Premium.
Edad y consumo	$r = 0.0065$	No se observa una relación lineal relevante.
País y plan	Premium > Estándar > Básico en los 7 países	El país no revierte el patrón general.

Hallazgo central: el plan de suscripción presenta la asociación descriptiva más clara con el tiempo mensual de visualización. Sin embargo, las distribuciones se superponen, por lo que el plan no determina completamente el comportamiento individual.

4. Escalamiento y análisis de componentes principales (PCA)

PCA se aplicó sobre edad, minutos mensuales, tickets de soporte y días desde el último ingreso. Se utilizaron 7.499 usuarios con fecha válida (93,74 % del dataset) y se aplicó StandardScaler, porque las variables estaban expresadas en unidades y rangos muy diferentes.

Componentes	Varianza acumulada	Decisión
PC1	25,43 %	Insuficiente para resumir la estructura.
PC1 + PC2	50,45 %	Se utiliza solo para visualización.
PC1 + PC2 + PC3	75,32 %	Todavía queda una pérdida cercana al 25 %.
Cuatro componentes	100 %	Se necesitan los cuatro para superar el 80 %.

Conclusión de PCA: las cuatro variables aportan dimensiones relativamente diferentes y no conviene reemplazarlas por solamente dos o tres componentes. La técnica fue útil para demostrar la baja redundancia, no para forzar una reducción.

5. Alcance y limitaciones

- No se conoce el procedimiento de muestreo, la población total ni el período exacto representado por el consumo mensual.
- Faltan variables comerciales y de comportamiento, como precio, antigüedad, dispositivos, renovaciones y cancelaciones.
- Las imputaciones de edad, minutos y tickets introducen incertidumbre, aunque fueron documentadas y justificadas.
- Permanecen 501 fechas desconocidas; PCA se realizó con los 7.499 casos completos.
- La correlación y PCA resumen principalmente relaciones lineales, y los resultados no permiten inferir causalidad.

6. Conclusiones y recomendaciones

El proceso transformó una base con problemas de calidad en un dataset reproducible de 8.000 usuarios únicos. El plan de suscripción se asocia con diferencias claras de consumo, mientras que la edad aislada no presenta una relación lineal relevante. El patrón Premium > Estándar > Básico se mantiene en los siete países, pero no puede afirmarse que el plan sea la causa del mayor consumo.

Para futuros estudios se recomienda incorporar documentación del origen de los datos, variables comerciales y temporales, controles de validación en la captura y análisis de sensibilidad ante otras estrategias de imputación. Un proyecto predictivo solo debería desarrollarse si se define una variable objetivo adecuada, por ejemplo abandono o renovación.

Conclusión general: la calidad del proyecto no depende de aplicar más técnicas, sino de justificar cada decisión, conservar la trazabilidad y comunicar conclusiones proporcionales a la evidencia disponible.

7. Disponibilidad del proyecto

El proyecto completo se encuentra disponible en los siguientes enlaces públicos:

Repositorio de GitHub:

https://github.com/nadiathir/PI_Mineria_Datos_1

Aplicación interactiva en Streamlit:

<https://pi-mineria-datos-thir-constantinidi-2026.streamlit.app/>

El repositorio contiene el dataset original y procesado, los cinco notebooks ejecutados, la aplicación Streamlit, el informe final y el registro de las transformaciones realizadas en logs/pipeline_log.csv.